



RELATÓRIO DE DESENVOLVIMENTO DO PROCESSO ETL E DO MODELO DIMENSIONAL DO DATA WAREHOUSE

Modelagem de *Data Warehouse* (Parte II)

Integrantes: Ana Clara de Jesus Nascimento, Mariana Rocha de Moraes,
Matheus Mangia Terra Suzano, Paulo Henrique Cotta de Assumpção,
Pedro Nunes de Oliveira Pessanha, Ryan Domingos dos Santos Saraiva
DRE: 124388471, 122147926, 123378716, 122156268, 123177330, 123137429

RIO DE JANEIRO
2026

Sumário

1	Introdução e Objetivos	2
2	Arquitetura Geral do ETL	2
3	Extração (E)	2
4	Transformação (T)	3
5	Modelo Dimensional e Carga (L)	4
6	Problemas e Observações Gerais	4
7	Conclusão	5

1 Introdução e Objetivos

Este documento reúne os comentários do grupo sobre o desenvolvimento do processo ETL e do modelo dimensional do *Data Warehouse* (DW) projetado para o grupo associado de seis locadoras de veículos. O ponto de partida foi a base transacional (OLTP) construída na Parte I — normalizada, em MySQL e seguindo o padrão ANSI SQL —, cujas operações de cadastro de clientes, controle de frota, reservas, locações e pátios compartilhados geram os dados de origem.

O objetivo que norteia a solução é deixar de responder a perguntas operacionais (“esta vaga está livre?”) e passar a responder a perguntas analíticas e históricas de forma integrada: ocupação dos pátios por grupo e origem, comportamento das locações ao longo do tempo e, sobretudo, a **previsão de ocupação de pátio por cadeia de Markov**, que exige a matriz de movimentação da frota entre os pátios. Toda a modelagem descrita a seguir foi orientada por esse conjunto de necessidades.

2 Arquitetura Geral do ETL

Optou-se por uma arquitetura em três camadas, materializadas em três bancos distintos, refletida na organização dos scripts do repositório (01_script-staging.sql, 02_script-extract.sql e 03_script-dw.sql).



Figura 1: Arquitetura em três camadas do processo ETL.

A separação foi uma escolha deliberada: a área de *staging* isola o DW das fontes operacionais (que continuam em produção), permite reprocessar a carga sem tocar nos sistemas de origem e oferece um ponto único onde os esquemas heterogêneos dos diferentes grupos da turma podem ser conformados antes de chegar às tabelas de fato e dimensão.

3 Extração (E)

A camada de *staging* foi modelada com cinco tabelas (Stg_patio, Stg_veiculo, Stg_cliente, Stg_motorista e Stg_locacao), correspondendo aos cinco conceitos do universo de discurso. As principais escolhas foram:

- **Colunas permissivas (NULL).** Todas as colunas de negócio aceitam valores nulos. A *staging* é uma área de pouso de dados brutos; restrições de integridade são responsabilidade do DW, não da extração. Isso evita que um registro problemático de origem interrompa toda a carga.
- **Rastreabilidade de origem.** Toda tabela carrega a coluna Sistema_Origem, preenchida com o identificador do grupo de origem ('Grupo01', 'Grupo02', 'Grupo03' ou 'Grupo04'). Esse campo é a chave da estratégia de integração: como os esquemas dos quatro grupos são extraídos para a mesma área, o sistema de origem distingue

e qualifica cada registro, viabilizando o conceito de “origem” exigido nos relatórios gerenciais (frota própria *vs.* frota das empresas associadas).

- **Auditoria de carga.** A coluna `Data_Carga` (`DATETIMEDEFAULTCURRENT_TIMESTAMP`) registra automaticamente o instante da ingestão, atendendo à exigência de especificar os tempos de acionamento das extrações.
- **Preservação das chaves naturais.** As chaves de origem (`Id_...oltp`) são mantidas na *staging*. Elas não viram chave do DW (que usa *surrogate keys*), mas são indispensáveis para resolver os relacionamentos durante a carga e para reconciliar registros.
- **Carga total (*full reload*).** O script de extração executa `TRUNCATE` seguido de `INSERT ... SELECT`. Dado o volume acadêmico e a natureza do trabalho, optou-se por recarregar integralmente a *staging* a cada execução, em vez de carga incremental, privilegiando simplicidade e reprodutibilidade.

4 Transformação (T)

Foi na transformação que concentramos a maior parte das decisões de modelagem, pois é aqui que o modelo normalizado da origem é reorganizado para o formato analítico. Os principais tratamentos:

- **Desnormalização por junção.** Atributos espalhados em várias tabelas da origem foram achatados em uma única linha por entidade. O veículo, por exemplo, recebe `categoria_nome` (de `Categoria`) e `empresa_dona` (de `Empresa`); o pátio e o cliente recebem `cidade/uf` a partir de `Endereco`. O objetivo é eliminar junções em tempo de consulta analítica.
- **Resolução da especialização PF/PJ.** Na origem, o cliente é especializado em `C_cliente_pf` e `Cliente_pj` (herança por discriminador). No DW isso foi unificado com `COALESCE(PF.Nome_cliente,PJ.Razao_social)`, gerando um único atributo `nome_ou_razao_social`, enquanto o discriminador `tipo_cliente` é preservado como atributo descritivo da dimensão.
- **Atributos derivados.** A `Data_Nascimento` do motorista é propositalmente carregada na *staging* apenas para servir de insumo ao cálculo da `faixa_etaria` na `dim_motorista` — um dado calculado, não copiado.
- **Dimensão de tempo gerada por procedimento.** A `dim_tempo` não vem de nenhuma fonte: é construída por uma *stored procedure* (`popular_dim_tempo`) que percorre o intervalo de 2020 a 2030 e deriva ano, mês, trimestre, dia da semana e a classificação “Dia Útil / Fim de Semana”. A diretiva `lc_time_names='pt_BR'` garante nomes de meses e dias em português.
- **Conformidade entre fontes.** A padronização de nomes, tipos e domínios na *staging* é o que permite integrar os esquemas dos demais grupos sob dimensões conformadas, sem que diferenças de nomenclatura de cada projeto contaminem o modelo final. Essa integração foi efetivamente implementada para quatro fontes: além do esquema próprio (`Grupo01`), o script de extração conforma os bancos dos `Grupo02`, `Grupo03` e `Grupo04`, cada um exigindo um tratamento específico. No `Gr`

upo02, o campo `mecanizacao` é mapeado para `Tipo_Cambio` e o nome do grupo do veículo e a empresa dona são trazidos por junções. No `Grupo03`, que separa locação, reserva, devolução e vaga, foi necessária uma cadeia de junções para reconstruir cada locação, todos os clientes são classificados como 'PF', o próprio cliente assume o papel de motorista, o ano do veículo recebe `CAST` para inteiro e o câmbio é derivado por `CASE` a partir do indicador de direção automática. No `Grupo04`, a distinção entre PF e PJ é inferida pela contagem de dígitos do `cpf_cnpj` e o valor total da locação é recuperado por uma subconsulta que soma os registros da tabela de pagamento. Atributos inexistentes em cada origem são preenchidos com `NULL`, preservando a estrutura comum da *staging*.

5 Modelo Dimensional e Carga (L)

O DW foi projetado em **esquema estrela**, com uma tabela de fato central e cinco dimensões. A `fato_locacao` tem como **grão** uma locação concretizada (uma linha por locação), com as métricas `qtd_locacao`, `km_rodados` e `valor_total`, e índices sobre todas as chaves estrangeiras para sustentar consultas OLAP.

Todas as dimensões usam *surrogate keys* inteiras (`sk_`, em `AUTO_INCREMENT`), mantendo as chaves de origem apenas como atributo (`id...oltp`). Isso desacopla o DW dos sistemas operacionais. A `dim_tempo` é a exceção: adota uma *smart key* no formato inteiro AAAAMMDD (ex.: 20260529), legível e eficiente para junções com o fato.

A decisão de modelagem mais relevante foi tratar `dim_patio` e `dim_tempo` como dimensões de papel duplo (*role-playing*). A `fato_locacao` referencia o pátio duas vezes (`sk_patio_retirada` e `sk_patio_devolucao`) e o tempo duas vezes (`sk_tempo_retirada` e `sk_tempo_devolucao`). Essa escolha não é apenas elegante: é exatamente o que viabiliza a análise central do trabalho. Cruzar pátio de retirada contra pátio de devolução, contando as locações, produz diretamente a matriz de movimentação da frota entre pátios — a matriz estocástica que alimenta a previsão de ocupação por cadeia de Markov.

6 Problemas e Observações Gerais

- **Heterogeneidade entre grupos.** O maior desafio conceitual não está no nosso próprio esquema, mas na integração com os esquemas projetados por outros grupos. A combinação `Sistema_Origem` + dimensões conformadas foi a resposta a esse problema, mas exige conferir manualmente a equivalência semântica de cada campo (daí a importância dos documentos de esquema dos demais grupos).
- **Locações em aberto.** Uma locação pode existir sem devolução registrada. Para isso, `sk_tempo_devolucao` é `NULL` até a entrega do veículo, evitando forçar uma data inexistente e permitindo separar locações em andamento das encerradas.
- **Pátio real vs. previsto na reserva.** Algumas fontes só registram o pátio de devolução depois que o veículo é efetivamente estacionado. No `Grupo03`, por exemplo, o pátio real de devolução é obtido pela vaga ocupada na devolução e, quando esta ainda não ocorreu, recorre-se ao pátio previsto na **reserva** via `COALESCE`. Esse tratamento garante que a coluna nunca fique sem valor e preserva a coerência da matriz de movimentação entre pátios mesmo para locações ainda não encerradas.

- **Perda de informação ao conformar fontes.** Nem toda fonte possui todos os atributos do nosso modelo. Quilometragem, ano do veículo, gênero do motorista e capacidade de pátio, por exemplo, inexistem em alguns dos grupos e entram como `NULL`. A integração é possível, mas o nível de detalhe analítico passa a variar conforme a origem — um efeito esperado ao unificar esquemas heterogêneos.
- **Achatamento da herança PF/PJ.** Unificar pessoa física e jurídica em uma só dimensão simplifica as consultas, mas implica conviver com atributos que só fazem sentido para um dos tipos; manter o discriminador `tipo_cliente` foi o compromisso adotado.
- **Localização do MySQL.** Gerar nomes de mês e dia em português dependeu de ajustar `lc_time_names`; sem isso, a `dim_tempo` sairia em inglês — um detalhe de ambiente que afeta diretamente a apresentação dos relatórios.
- **Aditividade das métricas.** `valor_total` e `km_rodados` são aditivos por locação; já `qtd_locacao` funciona como contador para agregações. A ausência de uma métrica de duração pré-calculada exige derivá-la em consulta a partir das duas chaves de tempo.

7 Conclusão

O processo de ETL e o modelo dimensional resultantes atendem ao objetivo que motivou a adoção de um *Data Warehouse*: consolidar, de forma íntegra e historicamente consistente, dados que nasceram dispersos em sistemas transacionais independentes. A arquitetura em camadas isolou as fontes operacionais; a *staging* com rastreabilidade de origem abriu caminho para a integração de múltiplos grupos sob dimensões conformadas; e o esquema estrela, com chaves substitutas e dimensões de papel duplo, transformou o registro operacional de uma locação em uma estrutura pronta para análise.

O ganho mais concreto é a aderência ao objetivo analítico final: ao modelar o pátio como dimensão de papel duplo, o próprio desenho do DW entrega a matriz de movimentação entre pátios praticamente de graça, conectando a modelagem dos dados à previsão de ocupação por cadeia de Markov. Em síntese, o trabalho confirma que a solução por *Data Warehouse* não foi apenas um repositório de dados integrados, mas a base estrutural que torna viáveis os relatórios gerenciais globais e as análises de decisão pretendidas pelo grupo de empresas.