

Solução Arquitetural Integrada de Dados End-to-End: Do Relacional Transacional ao Data Warehouse e Big Data Streams

Caso de Estudo: Ecossistema de Dados para Consórcio de Locação Veicular Compartilhada

Ana Clara N., Mariana M., Matheus S., Paulo A., Pedro P., Ryan S.

Universidade Federal do Rio de Janeiro
Disciplina: Big Data e Data Warehouse

2026

Agenda e Linha Evolutiva da Apresentação

Introdução e Alinhamento de Paradigmas

- O Desafio do Consórcio Compartilhado
- Evolução Arquitetural: OLTP → OLAP → Streams

Parte 1: Engenharia Transacional (OLTP)

- SBD Relacional e Restrições ACID
- Herança PF/PJ e Desacoplamento Lógico
- Controle de Vagas e Insumos de Markov

Parte 2: Integração e Data Warehouse (OLAP)

- Desacoplamento via *Staging Area*
- Colisão de Chaves Primárias Multi-Grupo
- Modelo Estrela e Geração da Matriz Estocástica

Parte 3: Escala e Big Data (IoT & IA)

- *Edge Computing* e Ingestão com Kafka
- Arquitetura Lambda (Flink, Spark, MapReduce)
- NoSQL Poliglota e Assistente Concierge RAG

Introdução e Contextualização Geral

O Problema de Negócio e a Transição de Paradigmas de Dados

O Cenário Logístico: Consórcio de Locadoras Compartilhadas

- **O Cenário de Negócio:** Associação estratégica de 6 empresas independentes de locação de automóveis que decidiram compartilhar fisicamente seus 6 pátios logísticos localizados em pontos críticos do Rio de Janeiro (Galeão, Santos Dumont, Rodoviária, Rio Sul, Nova América e Barra Shopping).
- **A Regra Crítica de Operação:** Rompimento das barreiras físicas de devolução. Um veículo retirado no pátio do Aeroporto do Galeão pode ser devolvido pelo cliente em qualquer um dos outros cinco pátios associados.

O Desafio em Engenharia de Dados

Essa flexibilidade exige uma infraestrutura unificada. Sistemas isolados gerariam falhas operacionais gravíssimas: venda de locações sem carros disponíveis (*overbooking*) ou pátios recebendo veículos acima de sua capacidade física de vagas.

A Jornada do Dado: Mudança de Paradigmas Computacionais

Para solucionar o problema do consórcio, nosso grupo desenhou uma jornada evolutiva dividida em três camadas tecnológicas estáveis, onde o dado evolui de sua natureza transacional até a inteligência preditiva:

- 1 **Parte 1 - O Dado em Movimento (SBD OLTP):** Construção do Modelo Entidade-Relacionamento estável em MySQL. Foco em registrar as operações diárias na ponta do balcão, garantindo transações velozes e integridade referencial absoluta.
- 2 **Parte 2 - O Dado Histórico (Data Warehouse OLAP):** Consolidação de dados heterogêneos de múltiplos grupos em um repositório central desnormalizado (Esquema Estrela). Foco em relatórios analíticos de diretoria e análise estocástica de pátios.
- 3 **Parte 3 - O Dado Inteligente (Big Data & IoT):** Expansão da infraestrutura para suportar fluxos massivos de frotas conectadas gerando eventos em tempo real, aliando aprendizado de máquina à IA Generativa.

Parte 1: Modelagem Relacional Operacional (SBD OLTP)

Garantindo a Consistência e as Restrições ACID na Origem

Por que o Modelo Relacional e um SGBD SQL na Camada Operacional?

- **O Objetivo:** Garantir que a operação de balcão das lojas seja estritamente confiável, impedindo falhas de concorrência (como dois operadores alugarem o mesmo chassi para clientes diferentes).
- **A Escolha Tecnológica:** SGBD Relacional baseado em **MySQL Operacional**.

Vantagem Arquitetural: Propriedades ACID vs. CAP Theorem

Sistemas operacionais de inventário físico exigem conformidade estrita às propriedades **ACID** (Atomicidade, Consistência, Isolamento e Durabilidade). Não podemos abrir mão da Consistência em favor da Disponibilidade (Teorema CAP) nesta fase.

- **Por que não NoSQL aqui?** Bancos NoSQL baseados em consistência eventual (como MongoDB ou Cassandra) poderiam permitir leituras defasadas, fazendo com que um pátio aceitasse uma devolução de carro mesmo já estando fisicamente lotado, quebrando a regra logística do negócio.

Pilar 1: Especialização de Clientes e a Dificuldade de Atributos Esparsos

- **A Dificuldade:** Representar dois perfis de clientes totalmente distintos sem inflar o banco com campos nulos e colunas esparsas: a Pessoa Física (CPF, Nome, Gênero) e a Pessoa Jurídica corporativa (CNPJ, Razão Social, Nome Fantasia).
- **A Solução (Herança Relacional):** Criação de tabelas supertipo e subtipos com integridade referencial de 1:1.

Estrutura de Modelagem Física

- **Tabela Cliente:** Centraliza dados comuns (Id_cliente, e-mail, telefone) e o campo discriminador crucial Tipo_cliente (*PF* ou *PJ*).
- **Cliente_pf e Cliente_pj:** Isolam os atributos exclusivos de suas respectivas naturezas.

O Vínculo do Motorista

Desacoplamos a entidade Motorista apontando para Cliente. Isso resolve a regra onde uma empresa (PJ) assina o contrato financeiro principal, mas delega a condução física a múltiplos funcionários cadastrados.

Pilar 2: Desacoplamento Lógico entre Reserva e Locação

- **O Objetivo:** Proteger a operação logística de pátio contra indisponibilidades imprevistas de chassis específicos e gerenciar a flutuação comercial de preços de forma flexível.
- **Contorno de Dificuldade:** Se o cliente reservasse uma placa específica com semanas de antecedência e esse veículo quebrasse na véspera, a reserva cairia e o negócio falharia.

A Solução Técnica: Abstração Lógica vs. Instanciação Física

- **Reserva (Nível Lógico):** O cliente escolhe e garante uma Categoria (ex: SUV Compacto), assegurando o Valor_previsto. Não há amarração com o ativo físico.
- **Locacao (Nível Físico):** Apenas no balcão de retirada, o sistema encerra o ciclo lógico da reserva e vincula o chassi real (Id_veiculo), placa, odômetro de saída (Km_retirada) e o termo de vistoria.

Pilar 3: Controle Dinâmico de Espaço e Vagas Compartilhadas

- **A Dificuldade:** Seis empresas concorrentes estacionam veículos no mesmo pátio físico. Como impedir matematicamente que dois sistemas aloquem carros diferentes no mesmo espaço físico simultaneamente?
- **A Solução:** Mapeamento granular através da tabela Vaga (estados dinâmicos: *Livre*, *Ocupada*, *Manutenção*).

A Blindagem por Constraint de Unicidade Física

Na tabela *Veiculo*, incluímos a chave estrangeira opcional (*Nullable*) chamada *Id_vaga* sob uma restrição severa de unicidade:

```
ALTER TABLE Veiculo ADD CONSTRAINT UQ_Vaga UNIQUE (Id_vaga);
```

- Quando o carro está sendo dirigido na rua, o campo fica nulo (NULL).
- Ao dar entrada em qualquer pátio, o operador associa uma vaga livre ao carro. A restrição **UNIQUE** força o motor do MySQL a rejeitar na hora qualquer transação simultânea que tente enfiar dois veículos na mesma vaga física.

Preparação de Insumos Transacionais para a Cadeia de Markov

- **O Requisito Estatístico:** O enunciado exige que o sistema viabilize o cálculo de probabilidades estocásticas (Cadeia de Markov) para prever a taxa de ocupação futura de cada pátio.
- **O Princípio de Markov:** O estado futuro depende apenas do estado atual. Precisamos saber matematicamente: *"Se um carro é retirado no Galeão, qual a probabilidade percentual de ele ser devolvido na Rodoviária?"*

A Captura dos Metadados Geográficos na Origem

Se falhássemos em capturar os pontos exatos de transição no OLTP, a análise preditiva na Parte 2 seria impossível por falta de histórico. Contornamos isso inserindo de forma explícita e obrigatória na tabela Locacao duas chaves estrangeiras apontando para a tabela de pátios: `Id_patio_real_retirada` e `Id_patio_real_devolucao`, associadas aos carimbos de tempo reais.

Parte 2: Engenharia do Data Warehouse e Pipeline ETL

Unificando Sistemas Heterogêneos de Múltiplos Grupos Operacionais

O Desafio da Integração Multi-Grupo e o Papel da Staging Area

- **O Objetivo Analítico:** Unificar e consolidar os dados das bases relacionais operacionais de **4 grupos distintos** (o nosso mais 3 grupos da turma) em um repositório central analítico para tomadas de decisão da diretoria global.
- **A Dificuldade Computacional:** Executar queries analíticas pesadas de agregação (como SUM, COUNT, GROUP BY) diretamente nos bancos de produção (OLTP) causaria travamentos nas frentes de caixa das lojas.

A Solução Arquitetural: Criação da Camada de Staging Area

Criamos um banco intermediário isolado chamado `locadora_dw_staging`. O processo de Extração executa dumps rápidos e diretos dos dados brutos das fontes para a *Staging*. Toda a computação pesada de higienização, conversão de caracteres e junções complexas ocorre exclusivamente na *Staging*, deixando a produção livre de sobrecarga.

A Dificuldade Crítica da Colisão de Chaves Primárias Homônimas

- **O Cenário de Colisão:** O Grupo 1 possui um pátio cadastrado com `Id_patio = 5` (Galeão). O Grupo 4 também possui um registro com `Id_patio = 5`, mas que aponta para o pátio do Santos Dumont.
- **O Risco:** Uma carga direta misturaria os dados analíticos de pátios e clientes diferentes de forma catastrófica, destruindo a veracidade dos relatórios de faturamento e ocupação.

A Solução Técnica: Injeção do Metadado `Sistema_Origem`

Redesenhamos todas as tabelas da *Staging Area* adicionando a coluna obrigatória `Sistema_Origem` (`VARCHAR`). Durante a extração, os dados recebem um carimbo de origem (ex: 'Grupo 01', 'Grupo 04'). A combinação de `Sistema_Origem` + `Id_oltp` cria uma chave lógica composta única que aniquila qualquer risco de colisão entre fontes heterogêneas.

Modelagem Dimensional Estrela (*Star Schema*) no DW Analítico

- **A Escolha de Modelo:** Migração do modelo normalizado (3FN) para o esquema estrela (`locadora_dw_analitico`), otimizando o desempenho de leitura de ferramentas de BI através da eliminação de Joins complexos.

Chaves Substitutas (*Surrogate Keys - SK*) vs. Chaves Naturais

As tabelas de dimensão utilizam chaves primárias numéricas sequenciais controladas pelo próprio DW (`sk_cliente`, `sk_veiculo`, `sk_patio`). Isso isola o ambiente analítico contra qualquer alteração estrutural ou mutação de chaves físicas ocorridas nos sistemas transacionais de origem.

Dimensões de Duplo Papel (*Role-Playing Dimensions*)

A tabela `fato_locacao` precisa referenciar o pátio de saída e o de chegada. Em vez de duplicar tabelas físicas no disco, criamos uma única dimensão `dim_patio` que é referenciada duas vezes na fato através de FKs distintas: `sk_patio_retirada` e `sk_patio_devolucao`.

Script de Ingestão: Extração Multi-Grupo com Resolução de IDs

O trecho real do nosso script `03_script-extract.sql` demonstra como os dados do Grupo 4 são capturados, limpos e integrados nativamente com a nossa padronização de chaves lógicas na *Staging* durante a madrugada:

```
-- Ingestao de dados historicos de locacao do Grupo 04 para a Staging Area
INSERT INTO locadora_dw_staging.Stg_locacao (
    Sistema_Origem, Id_locacao_oltp, Id_patio_retirada_oltp, Id_patio_devolucao_oltp,
    Id_veiculo_oltp, Id_cliente_oltp, Id_motorista_oltp, Data_Retirada, Data_Devolucao, Valor_Total
)
SELECT
    'Grupo 04',
    L.id_locacao,
    L.id_patio_retirada,
    L.id_patio_devolucao,
    L.id_veiculo,
    L.id_cliente,
    L.id_cliente, -- No modelo deles, o motorista assume o ID do cliente contratante
    L.data_retirada,
    L.data_devolucao,
    P.valor_total -- Captura agregada do faturamento na tabela associativa de pagamentos
FROM db_grupo_04.locacao L
LEFT JOIN (
    SELECT id_locacao, SUM(valor) AS valor_total
    FROM db_grupo_04.pagamento GROUP BY id_locacao
) P ON L.id_locacao = P.id_locacao;
```


Script de Carga Analítica: Desnormalização e Povoamento do DW

O script 04_transformacao_e_carga.sql demonstra a inteligência do pipeline de carga da tabela fato. O sistema busca as Chaves Substitutas (SK) corretas combinando o ID de origem ao metadado do grupo:

```
-- Processamento e Carga da Tabela Fato de Locacao buscando SKs correspondentes
INSERT INTO locadora_dw_analitico.fato_locacao (
    id_locacao_oltp, sk_cliente, sk_veiculo, sk_patio_retirada, sk_patio_devolucao,
    sk_tempo_retirada, sk_tempo_devolucao, qtd_locacao, valor_total_arrecadado, duracao_dias
)
SELECT
    L.Id_locacao_oltp,
    C.sk_cliente,
    V.sk_veiculo,
    P_RET.sk_patio AS sk_patio_retirada,
    P_DEV.sk_patio AS sk_patio_devolucao,
    CAST(DATE_FORMAT(L.Data_Retirada, '%Y%m%d') AS UNSIGNED) AS sk_tempo_retirada,
    CAST(DATE_FORMAT(L.Data_Devolucao, '%Y%m%d') AS UNSIGNED) AS sk_tempo_devolucao,
    1 AS qtd_locacao, -- Indicador aditivo padrao para contagem de registros analiticos
    L.Valor_Total,
    TIMESTAMPDIFF(DAY, L.Data_Retirada, L.Data_Devolucao) -- Metricacao fisica calculada no voo
FROM locadora_dw_staging.Stg_locacao L
JOIN locadora_dw_analitico.dim_cliente C      ON L.Id_cliente_oltp = C.id_cliente_oltp AND L.Sistema_Origem = C.sistema_origem
JOIN locadora_dw_analitico.dim_veiculo V      ON L.Id_veiculo_oltp = V.id_veiculo_oltp AND L.Sistema_Origem = V.sistema_origem
JOIN locadora_dw_analitico.dim_patio P_RET    ON L.Id_patio_retirada_oltp = P_RET.id_patio_oltp AND L.Sistema_Origem = P_RET.sistema_origem
LEFT JOIN locadora_dw_analitico.dim_patio P_DEV ON L.Id_patio_devolucao_oltp = P_DEV.id_patio_oltp AND L.Sistema_Origem = P_DEV.sistema_origem;
```

Entrega de Relatórios Gerenciais Globais (Itens 12.a e 12.b)

Com o Data Warehouse totalmente povoado, executamos consultas agregadas de altíssima velocidade para responder às exigências analíticas da diretoria do consórcio:

Query 12.a - Controle de Pátio Unificado (Ocupação por Grupo e Origem)

```
SELECT PR.nome_patio, V.categoria_nome, V.marca, V.modelo, V.empresa_dona AS Origem_Dona, SUM(F.qtd_locacao) AS Total
FROM fato_locacao F
JOIN dim_patio PR ON F.sk_patio_retirada = PR.sk_patio
JOIN dim_veiculo V ON F.sk_veiculo = V.sk_veiculo
GROUP BY PR.nome_patio, V.categoria_nome, V.marca, V.modelo, V.empresa_dona;
```

Query 12.b - Controle de Locações Ativas (Métrica de Tempo Restante)

```
SELECT V.categoria_nome, SUM(F.duracao_dias) AS Dias_Acumulados,
       COUNT(CASE WHEN F.sk_tempo_devolucao IS NULL THEN 1 END) AS Veiculos_Ativos_Na_Rua
FROM fato_locacao F
JOIN dim_veiculo V ON F.sk_veiculo = V.sk_veiculo
GROUP BY V.categoria_nome;
```

Entrega de Relatórios Gerenciais Globais e Matriz de Markov

Query 12.c - Controle de Reservas Ativas (Métricas de Demanda Futura)

```
SELECT CAT.nome_categoria, T.ano, T.nome_mes, SUM(FR.duracao_prevista_dias) AS Dias_Planejados, SUM(FR.valor_previsto) AS
Receita_Previsa_USD
FROM fato_reserva FR
JOIN dim_categoria CAT ON FR.sk_categoria = CAT.sk_categoria
JOIN dim_tempo T ON FR.sk_tempo_reserva = T.sk_tempo
GROUP BY CAT.nome_categoria, T.ano, T.nome_mes;
```

Query 13 - Geração da Matriz Base de Markov (Frequência Estocástica de Transição)

```
WITH Movimentacoes AS (
    SELECT PR.nome_patio AS Origem, PD.nome_patio AS Destino, SUM(F.qtd_locacao) AS Total_Movidos
    FROM fato_locacao F
    JOIN dim_patio PR ON F.sk_patio_retirada = PR.sk_patio
    JOIN dim_patio PD ON F.sk_patio_devolucao = PD.sk_patio WHERE F.sk_tempo_devolucao IS NOT NULL
    GROUP BY PR.nome_patio, PD.nome_patio
), TotalSaidas AS (
    SELECT Origem, SUM(Total_Movidos) AS Total_Geral_Saidas FROM Movimentacoes GROUP BY Origem
)
SELECT M.Origem, M.Destino, M.Total_Movidos, (M.Total_Movidos / T.Total_Geral_Saidas) * 100 AS Percentual_Probabilidade_Transicao
FROM Movimentacoes M JOIN TotalSaidas T ON M.Origem = T.Origem;
```

Parte 3: Proposta Executiva e Solução Big Data

Escala, Ingestão de Streams, IoT e Inteligência Artificial Generativa

O Ecossistema de Carros Inteligentes e os 5 V's do Big Data

- **Evolução:** Aquisição de frotas conectadas transmitindo telemetria e status mecânico a cada **3 segundos**.
- **Alinhamento com as Dimensões de Big Data:**
 - **Veracidade:** *Edge Computing* filtrando ruídos na origem.
 - **Valor:** Precificação dinâmica e Assistente de Voz IA.
- **Volume:** Gigabytes diários de telemetria contínua da frota.
- **Velocidade:** Processamento em fluxo para alertas imediatos.
- **Variedade:** JSON de IoT, SQL estruturado e áudio (voz).

O Papel das Etapas Anteriores (MVP)

O modelo relacional em MySQL (Partes I e II) atua como o **MVP/Piloto** validado. A arquitetura NoSQL/Big Data traz a escala elástica necessária para a expansão do consórcio, sem descontinuar o DW legado.

Computação de Borda (Edge Computing) e Divisão de Fluxos

- **Hardware Embarcado:** Gateway industrial baseado em **ARM Cortex-A72** (Quad-core, 1.5GHz, 4GB RAM), barramento CAN do motor e modems automotivos **4G/5G LTE Categoria 4**.
- **Software de Borda:** Atua como primeira barreira inteligente, dividindo o processamento local em:

Divisão de Fluxos de Transmissão

- **Fluxo de Rotina (Batch/Stream Agregado):** Acumula dados em uma *Tumbling Window* local de 1 segundo. Calcula médias/máximas de RPM e velocidade, enviando lotes binários compactados a cada **10 segundos** para a nuvem.
- **Fluxo de Eventos Críticos (Alerta Imediato):** Ativado por gatilhos físicos severos (ex: desaceleração abrupta $> 2.5G$ no acelerômetro). Interrompe a rotina e aloca banda total para enviar dados brutos em milissegundos.

Protocolo de Comunicação: MQTT (Message Queuing Telemetry Transport)

- **Por quê?** Leve, projetado para redes móveis instáveis, suporte a níveis de QoS e recurso de *Last Will and Testament* para lidar com túneis e áreas de sombra.
- **Por que não HTTP/REST?** O cabeçalho HTTP possui alto *overhead*. Enviar POSTs a cada 3s consumiria mais banda trafegando metadados de rede do que dados úteis dos sensores.

Formato de Serialização: Apache Avro

- **Por quê?** Compactação binária extremamente eficiente que reduz custos de dados móveis. Possui separação estrita do *schema*, permitindo evolução da estrutura sem quebrar os consumidores.
- **Por que não JSON ou XML?** XML é excessivamente verboso. O JSON repete os nomes das chaves/colunas em cada linha enviada, multiplicando exponencialmente os custos de tráfego e armazenamento.

Camada de Ingestão e Barramento de Eventos com Apache Kafka

- **Mecanismo Pub/Sub:** Desacoplamento absoluto entre os Gateways MQTT dos veículos (produtores) e os motores analíticos (consumidores).
- **Topologia de Tópicos Particionados:**
 - `topic_telemetria_rotina`: Fila particionada focada em alta taxa de transferência (*High Throughput*).
 - `topic_alertas_criticos`: Fila isolada e prioritária focada em baixíssima latência (*Low Latency*).
- **Resiliência Industrial:** Particionamento baseado no `ID_Veiculo` como chave, garantindo ordenação cronológica rigorosa de cada carro via *timestamp*. Fator de replicação igual a 3 distribuído na nuvem.

Por que o Apache Kafka e não outros?

O Kafka grava mensagens em logs imutáveis sequenciais em disco, suportando milhões de eventos por segundo. Sistemas como **RabbitMQ** mantêm filas em memória RAM e apagam mensagens pós-consumo, o que causaria estouros de memória e perda de histórico analítico sob a volumetria do consórcio.

Camada de Processamento: Arquitetura Lambda e Integração com o Legado

- **A Decisão pela Arquitetura Lambda:** Separação estratégica do fluxo analítico em duas vias independentes:
 - **Via Rápida (Hot Path):** Processamento direcionado ao monitoramento em tempo real, segurança e tomada de ação imediata.
 - **Via Tradicional (Cold Path):** Consolidação de exaustão histórica, auditorias pesadas e fechamento de contratos.

A Ponte Técnico-Analítica com o Data Warehouse Legado (MySQL)

- Os dados refinados no *Cold Path* são salvos em formato **Delta Lake** (garantindo transações ACID sobre arquivos colunares Parquet).
- Durante a madrugada, rotinas agendadas lêem esses dados consolidados (Km total, horas rodadas) e updateam periodicamente a tabela fato fato_locacao (ou tabelas fato agregadas de telemetria) no MySQL.
- Atributos descritivos e cadastrais estruturados continuam residindo com segurança na dimensão dim_veiculo, preservando o modelo dimensional estrela da Parte II.

Motores de Processamento Distribuído: Flink, Spark e MapReduce

- **Apache Flink (Hot Path - True Streaming):**

- Consome o `topic_alertas_criticos` evento por evento (*event-driven*) em milissegundos.
- Opera com janelas deslizantes (*Sliding Windows*) para calcular o **Score Instantâneo de Risco** (freadas/acelerações severas) e disparar alertas de acidentes.

- **Apache Spark (Cold Path - Micro-batching / Machine Learning):**

- Orquestra micro-lotes de alta eficiência e aplica modelos preditivos via **Spark MLlib**.
- **Manutenção Preditiva:** Analisa desvios térmicos e de pressão para prever falhas mecânicas iminentes antes que o veículo quebre na rua, gerando ordens automáticas de parada.

- **Hadoop MapReduce (Agregação de Exaustão):**

- Mantido para processar em lote **petabytes de logs brutos históricos com mais de 1 ano**. O processamento baseado em disco do MapReduce garante resiliência e segurança de memória (*Out of Memory*) onde clusters Spark em memória RAM falhariam devido ao volume extremo.

Arquitetura do Cluster na Nuvem

- **1 Nó Mestre (Master):** 8 vCPUs, 32GB RAM para coordenação de recursos e jobs.
- **6 Nós de Trabalho (Workers):** 16 vCPUs, 64GB RAM e 500GB SSD NVMe local para cache de disco por nó.
- **Total Distribuído:** 96 núcleos de processamento e 384GB de memória RAM.

Persistência Poliglota: O Banco Certo para o Dado Certo

- **Amazon S3 / HDFS (Data Lake):** Repositório bruto de arquivos compactados Parquet/Delta.
- **Apache Cassandra (NoSQL Wide-Column Store):** Suporta a altíssima taxa de escrita paralela da telemetria de rotina.
- **Redis (NoSQL Key-Value em Memória):** Armazena o último estado conhecido do carro em microssegundos para o mapa vivo.
- **MongoDB Atlas (NoSQL Document Store):** Perfis de condução, catálogos georreferenciados e índices vetoriais para a IA.

Dashboard em Tempo Real via WebSockets (Painéis 1 a 3)

- **Arquitetura de Atualização:** Interface web alimentada por conexões contínuas bi-direcionais via **WebSockets** diretamente acopladas ao Flink e Redis.

Detalhamento dos Painéis Operacionais

- 1 **Painel de Viagens em Andamento:** Renderiza a posição geoespacial ao vivo da frota ativa. Sobreposição de forma analítica dados externos consumidos via **Google Maps Traffic API** (engarrafamentos) e **OpenWeather API** (condições meteorológicas severas, chuva forte) para antecipar atrasos e redefinir rotas operacionais.
- 2 **Painel de Reservas:** Exibe gráficos de linha temporais com a **taxa de ocupação preditiva**, cruzando contratos abertos, agendamentos futuros e estimativas de devolução nas próximas 24 horas.
- 3 **Painel de Locações:** Visão executiva financeira com indicadores de faturamento acumulado no dia, ticket médio por categoria e ranking de giro de frota por agência associada.

Dashboard em Tempo Real via WebSockets (Painéis 4 a 6)

Detalhamento dos Painéis de Controle e Segurança

- 1 **Painel de Cobranças e Financeiro:** Monitora o faturamento dinâmico e gamificação. Aplica taxas ativas na pré-fatura do contrato caso o score de condução do motorista indique desgaste severo e acelerado de pneus ou motor.
- 2 **Painel de Emergências (Prioridade Máxima):** Alertas visuais e sonoros instantâneos em caso de desaceleração violenta ou *airbag*. Dispara automaticamente um **Dossiê Digital de Regulação** compilando a telemetria completa dos 60 segundos pré e pós-evento, geolocalização, carimbo de tempo e imagens das câmeras 360° embarcadas, agilizando processos com a seguradora.
- 3 **Painel de Oficina e Manutenção:** Lista veículos com anomalias mecânicas apontadas pelo aprendizado de máquina do Spark MLlib. Emite ordens de serviço preditivas e efua o bloqueio automatizado do chassi para novas locações no sistema OLTP.

Especificação Funcional da IA de Voz (Concierge de Viagem RAG)

- **Abordagem:** IA Generativa controlada por **RAG (Retrieval-Augmented Generation)**, eliminando alucinações ao forçar a LLM a buscar dados apenas nos catálogos homologados e georreferenciados do consórcio.

Fluxo Arquitetural Passo a Passo

- 1 **Captura:** O condutor aciona o botão no volante e fala. O sistema grava o áudio (Opus/WAV) e envia via MQTT.
- 2 **Transcrição (STT):** O áudio é convertido em string de texto utilizando a **API OpenAI Whisper**.
- 3 **Busca Vetorial (RAG):** O sistema lê a latitude/longitude atual do carro no Redis e faz uma busca por similaridade de cosseno (*Vector Search*) no **MongoDB Atlas** em um raio de 5 km por locais bem avaliados (> 4.5).
- 4 **Geração (LLM):** O contexto extraído do MongoDB e as travas de segurança são injetados no prompt da **API GPT-4o**.
- 5 **Síntese (TTS):** O texto de retorno é convertido em voz ultra-realista via **API OpenAI TTS**.
- 6 **Injeção GPS:** O áudio é reproduzido e o payload JSON com as coordenadas é injetado no navegador do carro.

IA Concierge: Cenário Prático e Tratamento de Exceções

Exemplo de Prompt Interno Injetado

```
[Instrucao]: Voce e o Concierge da Locadora. Use estritamente o contexto abaixo. Nao invente locais.  
[Localizacao Carro]: Av. Atlantica, Copacabana.  
[Dados MongoDB]: 1. Don Camillo (Massa, Nota 4.8, 600m). 2. La Trattoria (Massa, Nota 4.6, 1.2km).  
[Pergunta Usuario]: "indica um lugar bom para comer massa agora perto de onde estou."
```

Retorno da Voz: *"Encontrei o restaurante Don Camillo, excelente para massas, com nota 4.8 a apenas 600 metros de você. Rota configurada no seu GPS!"*

Tratamento de Exceções e Falhas

- **Queda de Sinal (Túnel):** O gateway de bordo detecta o *timeout* e emite áudio local pré-gravado: *"Conexão indisponível no momento. Tente novamente ao sair do túnel."*
- **Raio Vazio (Sem Dados):** Se a busca vetorial retornar vazia, a LLM é proibida de alucinar e diz: *"Não encontrei opções de massa em um raio de 5km. Deseja expandir a busca?"*
- **Lentidão nas APIs Externas:** *Circuit Breaker* configurado para 3 segundos aborta a chamada externa e emite aviso mantendo a rota principal.

Conformidade Estrita com a LGPD

- **Privacy by Design:** O assistente de IA e leituras de agendas iniciam desativados por padrão. Exigem **Opt-In** contratual explícito do cliente.
- **Anonimização de Rotas:** Históricos de GPS salvos no Data Lake (S3) e DW (MySQL) para IA são anonimizados e desvinculados do CPF do condutor.
- **Criptografia:** Dados em repouso protegidos por **AES-256** e em trânsito por **TLS/SSL** ponta a ponta.

Estimativa Financeira Mensal (Pay-as-you-go)

- **Kafka (Ingestão/Confluent):** US\$ 150.00
- **Databricks / Spark / Flink:** US\$ 850.00
(Cluster com auto-scaling na madrugada)
- **Data Lake (Amazon S3):** US\$ 80.00
(Políticas de ciclo de vida Glacier)
- **MongoDB Atlas + Redis Enterprise:** US\$ 320.00
- **APIs de IA (Whisper/GPT):** US\$ 0.05 por locação ativa (Custo variável elástico)

Custo Fixo Estimado: $\approx$ US\$ 1,400.00 / mês

Conclusão: A Infraestrutura de Dados Unificada do Consórcio

- **Fundação Sólida (Parte 1):** O modelo transacional OLTP garantiu o respeito às regras físicas e consistência ACID no compartilhamento de pátios.
- **Inteligência Analítica (Parte 2):** O Data Warehouse em esquema estrela e os pipelines de ETL consolidaram visões gerenciais de histórico e forneceram a base para as matrizes de Markov.
- **Disrupção Preditiva (Parte 3):** O ecossistema de Big Data, IoT e IA Generativa (RAG) preparou o consórcio para a baixa latência, faturamento por comportamento e assistência conectada ao motorista.

O Maior Ganho Arquitetural

A solução prova que o moderno mundo do Big Data não invalida o legado relacional: o fluxo de dados em lote do *Cold Path* retroalimentando o MySQL unifica a governança tradicional com o poder de escala e streaming em tempo real.

Obrigado pela atenção!